

Etude de l'impact écologique des chats domestiques

Fouille de données

Rapport de projet
Effectué dans le cadre du parcours
Master 1 Bioinformatique et Biologie des Systèmes
Année universitaire 2024-2025



FÉLINOMICON

L'ALGORITHME OCCULTE DU FÉLIN MODERNE

Image générée par IA générative⁽¹⁾

RÉSUMÉ

Les chats domestiques, bien que issus d'un environnement anthropisé, conservent un instinct de prédation susceptible de perturber significativement la biodiversité locale. Le projet ***Félinomicon*** s'inscrit dans une approche de fouille de données écologique visant à caractériser et modéliser le comportement de chasse des chats domestiques à partir de données comportementales enrichies par des capteurs GPS.

Après une phase de structuration rigoureuse des jeux de données australiens, combinant extraction automatisée d'attributs, normalisation et codage, une analyse exploratoire et la mise en œuvre conjointe du clustering non supervisé (k-means) et de la classification supervisée (Analyse Discriminante Linéaire, AutoML via auto-sklearn) ont permis d'atteindre une précision globale de 75,46 % dans la prédiction du comportement de chasse.

Cependant, l'analyse critique souligne l'importance de facteurs non mesurés et la présence de comportements partiellement indéterminés ("Unknown"), limitant la séparation stricte des classes. Nos résultats montrent que, loin d'être monolithique, le comportement de prédation est hautement multifactoriel et plastique. L'intégration croisée de méthodes classiques et d'apprentissage automatique apparaît ainsi essentielle pour capturer la complexité comportementale des espèces domestiques et anticiper leur impact écologique.

Points clés :

- Impact écologique du comportement de chasse chez le chat domestique.
- Analyse de données comportementales et GPS par fouille de données.
- Modélisation prédictive via Analyse Discriminante Linéaire et AutoML.
- Complexité comportementale multifactorielle et variabilité intra-classe.
- Perspectives d'application pour la conservation de la biodiversité.

Mots clés : Australie, France, biodiversité, écologie, environnement, statistiques, analyses multivariées, modèle prédictif, apprentissage automatique, *datamining*, chat domestique (*Felis catus*), prédation, comportement animalier

CONTEXTE

La biodiversité mondiale subit une pression croissante liée aux activités humaines. Parmi les facteurs parfois sous-estimés figure l'impact des animaux domestiques, et notamment des chats. Leur instinct naturel de chasse fait peser une menace importante sur la petite faune locale, particulièrement dans les milieux urbains et périurbains. Ce phénomène soulève d'importantes questions de conservation et de gestion de la biodiversité.

Dans ce contexte, notre projet intitulé **Félinomicon** s'inscrit dans une démarche de **datamining écologique**, visant à caractériser **l'impact écologique des chats domestiques** sur leur environnement. L'objectif principal est de mieux comprendre **quels profils de chats** (âge, sexe, mode de vie, stérilisation, habitudes de chasse...) sont les plus susceptibles de menacer la biodiversité locale. Ainsi, ce projet vise à **identifier les facteurs prédictifs** du comportement de chasse, et donc du risque écologique associé, en mobilisant des approches bioinformatiques de **prétraitement de données**, de **réduction dimensionnelle**, de **clustering** et de **modélisation supervisée**.

La problématique étudiée ici est donc :

Quels facteurs comportementaux et démographiques des chats domestiques influencent leur impact écologique, et comment peut-on les identifier par des méthodes de fouille de données ?

Pour y répondre, nous nous appuyons sur un jeu de données collecté via des capteurs GPS et des relevés comportementaux, enrichi par un ensemble d'analyses statistiques, de clustering et de modélisation automatique. Ce travail s'inscrit dans une démarche intégrée, associant traitement de données massives, visualisation avancée, apprentissage automatique et évaluation de modèles, dans un cadre rigoureusement reproductible.

ANALYSE

Objectifs détaillés

Afin de répondre précisément à la problématique posée, notre projet s'articule autour de plusieurs étapes complémentaires.

Tout d'abord, un **travail de nettoyage et de structuration des données** sera réalisé, consistant à extraire des variables pertinentes à partir des jeux de données bruts, à corriger les valeurs manquantes, à standardiser les formats, ainsi qu'à concevoir de nouvelles variables comportementales.

Ensuite, une **analyse exploratoire** sera menée pour examiner la distribution des variables individuelles et leurs relations avec le comportement de chasse, en s'appuyant sur des méthodes de visualisation et de réduction de dimensionnalité telles que l'ACP (Analyse en Composantes Principales), le MDS (MultiDimensional Scaling) et l'UMAP (Uniform Manifold Approximation and Projection).

Un **clustering non supervisé** sera ensuite mis en œuvre afin d'identifier d'éventuels groupes homogènes de chats sur la base de leurs caractéristiques, indépendamment de toute information relative à leur comportement de chasse.

Parallèlement, une **modélisation prédictive supervisée** sera développée afin de construire des modèles capables de prédire la propension d'un chat à chasser, en fonction de ses caractéristiques individuelles et de son environnement.

Enfin, une **évaluation rigoureuse** sera réalisée pour valider les performances des modèles et des regroupements identifiés, à l'aide de métriques quantitatives telles que la pureté, l'entropie, le coefficient de silhouette et les matrices de confusion.

Approche méthodologique

Pour atteindre les objectifs fixés, plusieurs étapes méthodologiques ont été mises en place.

La première phase a consisté en une **préparation rigoureuse des données**, comprenant la séparation des jeux de données GPS et des caractéristiques individuelles, l'extraction automatique d'informations comportementales à l'aide d'expressions régulières (par exemple, le nombre de proies capturées par mois ou le nombre d'heures passées à l'intérieur), ainsi que le codage des variables qualitatives et quantitatives de manière adaptée aux futures analyses statistiques.

Une **analyse exploratoire préliminaire** a ensuite été réalisée, reposant sur des visualisations de densité, des diagrammes en barres et des matrices de corrélation, afin de détecter les principales tendances et dépendances au sein des données. Une normalisation par **Z-score** a également été appliquée pour assurer des comparaisons robustes entre variables de natures différentes.

Concernant la **réduction dimensionnelle**, plusieurs méthodes ont été mobilisées : l'ACP pour explorer la variance entre les individus, ainsi que le MDS et l'UMAP pour visualiser les structures non linéaires sous-jacentes dans les données.

Dans le cadre du **clustering non supervisé**, des algorithmes de k-means ont été utilisés pour identifier des regroupements naturels d'individus, et le nombre optimal de clusters a été déterminé via l'analyse du coefficient de silhouette.

Enfin, une phase **d'apprentissage supervisé** a été conduite : l'Analyse Discriminante Linéaire (LDA) a permis de classer les individus en fonction de leur comportement de chasse, et cette approche a été complétée par l'utilisation d'un processus d'**AutoML** (Automated Machine Learning), notamment Auto-sklearn, afin d'automatiser la sélection du meilleur modèle prédictif.

CONCEPTION

Approche générale

À la lumière des résultats de l'analyse exploratoire, une **approche en deux temps** a été retenue. Dans un premier temps, les données ont été **structurées de manière propre et exploitable**, afin de garantir leur qualité pour les analyses statistiques et les phases de modélisation.

Dans un second temps, deux types de méthodes analytiques ont été successivement appliqués : d'abord des **méthodes de clustering non supervisé** pour identifier des regroupements naturels d'individus en fonction de leurs caractéristiques, puis des **méthodes supervisées** destinées à prédire la propension au comportement de chasse à partir des variables individuelles et environnementales.

Ce choix méthodologique est directement motivé par la complexité du phénomène étudié : le comportement de chasse résulte probablement de **l'interaction de multiples facteurs** (tels que l'âge, le sexe ou les conditions de vie domestique), ce qui rend nécessaire une **phase exploratoire non supervisée** pour détecter des structures latentes, suivie d'une **modélisation supervisée** pour affiner la prédiction de ce comportement.

Constitution de la matrice individus-variables-classes

La construction de la base de données finale repose sur plusieurs étapes méthodologiques :

- **Sélection des variables :**
 - Données issues des fichiers **PetCatsAustraliaGPS** et **PetCatsAustraliaCaract**.
 - Variables extraites : âge (**animal.age**), sexe (**animal.sex**), statut reproductif (**animal.reproductive.condition**), nombre d'heures passées à l'intérieur (**Hrs.indors**), nombre de chats dans l'environnement immédiat (**N.neighbours**), nombre de proies par mois (**N.prays**), etc.
- **Transformation des données :**
 - Extraction par expressions régulières pour obtenir des variables numériques à partir de champs textuels composites (**animal.comments**, **manipulation.comments**).
 - Conversion des variables qualitatives en variables factorielles (e.g., sexe codé en 0/1).

- **Nettoyage des données :**
 - Suppression des individus présentant des valeurs manquantes sur des variables clés.
 - Normalisation des variables continues par **Z-score** pour assurer l'homogénéité des échelles.
- **Ajout de la classe cible :**
 - Comportement de chasse (**Hunt**) codé en trois catégories : "Yes", "No", "Unknown".

Méthodes utilisées pour la production de résultats

Une fois la matrice de données construite et préparée, différentes méthodes analytiques ont été appliquées pour explorer et modéliser les structures sous-jacentes.

Concernant le **clustering non supervisé**, l'algorithme des **k-means** a été utilisé afin d'explorer la structure latente des données, avec une visualisation des regroupements obtenus par trois méthodes de réduction dimensionnelle complémentaires : **ACP, MDS et UMAP**.

Pour la **classification supervisée**, une **LDA** a été employée pour prédire la classe de chasse à partir des variables individuelles. Cette approche a été enrichie par l'utilisation de la plateforme **Auto-sklearn**, permettant de recourir à l'**apprentissage automatique automatisé (AutoML)** afin d'explorer automatiquement d'autres modèles de classification tel que `random_forest`, `lda`, `mlp`, `gaussian_nb`, `k_nearest_neighbors` et ainsi optimiser les hyperparamètres associés.

Méthodologie d'évaluation

L'évaluation de la qualité des résultats repose sur deux axes principaux : l'**évaluation non supervisée** pour les méthodes de clustering et l'**évaluation supervisée** pour les modèles de classification.

Dans le cadre de l'évaluation non supervisée, plusieurs indicateurs ont été utilisés pour analyser la qualité des regroupements obtenus. Le **coefficient de silhouette** permet de mesurer à la fois la compacité interne des clusters et leur séparation relative les uns par rapport aux autres. La **pureté** évalue la proportion d'individus correctement regroupés au sein de leur classe dominante, tandis que l'**entropie** sert à mesurer la dispersion des différentes classes au sein des clusters, renseignant ainsi sur leur homogénéité.

Pour l'évaluation supervisée des modèles prédictifs, la **matrice de confusion** a été mobilisée afin de comparer les classes prédites aux classes observées. Le **taux d'erreur** et la **précision globale** fournissent des indicateurs synthétiques de la performance des modèles. Une **analyse comparative** entre l'ACP et la LDA a également été menée pour évaluer la capacité de séparation des classes dans les espaces projetés par ces deux méthodes.

Afin de limiter les risques de **surapprentissage**, chaque modèle a été validé par une stratégie de **séparation des données** en deux sous-ensembles distincts : un **jeu d'apprentissage** comprenant deux tiers des données, destiné à l'entraînement des modèles, et un **jeu de test** constitué du tiers restant, utilisé pour évaluer leur performance sur des données inédites.

RÉALISATION

Préparation des données


La première étape a consisté en la préparation et la structuration du jeu de données :

- **Extraction et nettoyage :**
 - Les fichiers **PetCatsAustraliaGPS** et **PetCatsAustraliaCaract** ont été importés dans R.
 - Les informations comportementales (**Hunt**, **N.pray**, **Hrs.indors**, **N.neighbours**) ont été extraites via expressions régulières à partir des champs textuels.
 - Les valeurs aberrantes et les données manquantes ont été traitées :
 - Suppression des individus avec données critiques manquantes.
 - Recodage des modalités ("Neutered", "Spayed", etc.) en catégories simplifiées.

- **Transformation :**
 - Toutes les variables numériques ont été standardisées via **Z-score** ($value.z = (value - mean)/sd$).
 - La matrice finale comprend uniquement les individus complets et normalisés.

Analyse exploratoire

- **Visualisations préliminaires :**
 - Densités comparatives selon la variable **Hunt** pour les variables **animal.sex**, **animal.age**, **animal.reproductive.condition** et **N.neighbours**.
 - Matrices de corrélation pour détecter d'éventuelles redondances entre variables.
- **Réduction dimensionnelle :**
 - **ACP** : conservation des deux premières composantes principales expliquant 29,7% de la variance totale.




Projection ACP

- **MDS et UMAP** : cartographies alternatives confirmant la structure des groupes.



Projection UMAP



projection MDS

Clustering non supervisé

- **Application du k-means :**
 - Testé pour différentes valeurs de k (de 2 à 20).
 - Le **coefficient de silhouette** maximum a été obtenu pour **k = 19**, soulevant un problème sous-jacent, éventuellement dans le nettoyage des données (trop peu sélectif) ou bien cela tend à démontrer qu'il n'existe pas de corrélation entre les caractéristiques des chats et la classe à laquelle ils appartiennent.


- **Résultats :**

- Les clusters obtenus ne montrent aucune séparation avec un chevauchement presque total entre chasseurs et non-chasseurs, ce qui indique une influence multifactorielle du comportement.

Classification supervisée

- **LDA :**

- Modèle entraîné sur un jeu d'apprentissage représentant 2/3 des données.
- Les projections LD1 et LD2 montrent une bonne séparation des classes **Yes** et **No**.



Projection LDA

- **Matrice de confusion** obtenue :

Classe	ID	Sensibilité	Spécificité	Précision	Prévalence
Chasseurs (menace à l'écosystème)	0.586269601079213	99,16%	15,62%	57,39%	71,99%
Non chasseurs (protecteurs de la faune... par inactivité)	-2.16472428387967	27,83%	99,44%	63,63%	13,71%
Inconnu (ni chasseurs, ni pacifistes... des félins sous couverture)	-0.78922734140023	1,81%	99,51%	50,66%	14,30%

Entre prédateurs déclarés, fervents partisans de la sieste, et individus aux activités soigneusement dissimulées, les chats étudiés offrent un large spectre d'interactions — ou d'absence d'interaction — avec l'écosystème.

- **Accuracy** globale : 75,46%
- Taux de confusion relativement faible entre classes opposées (**Yes** vs **No**).
- Un déséquilibre entre la spécificité et la sensibilité peut venir de la prévalence conséquente des chats appartenant à la classe des chasseurs.

- **AutoML avec auto-sklearn :**

- Automatisation de la recherche du meilleur modèle.
- Modèle entraîné sur un jeu d'apprentissage représentant ½ des données
- Modèles testés :

Modèle	Précision sur la prédiction de la variable...			Temps d'exécution	Commentaires
	Hunt	N.pray	Hrs.indors		
FA (Forêt aléatoire)	NULL	NULL	NULL	NULL	Approche incompatible avec le jeu de données
k-NN (k nearest neighbours)	100%	100%	100%	3 minutes	Solution la plus adaptée
NB (naïve bayesien)	80%	63%	41%	3 minutes	Précision et temps de calcul acceptables
LDA	89%	72%	74%	3 minutes	
MLP (Multi-Layer Perceptron) + FA+ k-NN +NB+LDA	100%	100%	100%	20 minutes	Approches combinées conduisant à une bonne précision mais à un temps de calcul élevé

Etude sur un nouveau jeu de données

Nous avons établi un **protocole RGPD**, une **AIPD** et un **registre des traitements des données** afin de pouvoir collecter nous-mêmes nos données d'étude et de sécuriser les informations sensibles.

La collecte s'est effectuée dans le **Sud-Ouest de la France**, après une diffusion de la proposition de participation. Un mail a été envoyé aux personnes souhaitant participer avec une fiche à retourner.

Les données ont ensuite été compilées dans un fichier csv. Afin de permettre l'analyse et la prédiction par le modèle généré par le script **Clusteror**.

Certaines données sont absentes du fait du temps de recueil des données, notamment les **variables spatio-temporelles**. Pour pallier cela, un **nouveau jeu de données** a été créé à partir des chats australiens en retirant les valeurs qui manquent aux chats français. Un **nouveau modèle a été entraîné** à partir de ces données avant de le tester sur notre jeu de données.

Notre jeu de données est composé de **15 individus**. Il est important de noter que notre jeu de données ne contient **pas de valeurs indéterminées**. Après un certain nombre d'itérations, on peut notamment observer la **matrice de confusion** suivante et calculer la **spécificité** et la **sensibilité** de notre modèle par rapport à notre jeu de données.

Matrice de confusion		Prédits		
		NA	No	Yes
Réels	NA	0	0	0
	No	0	2	0
	Yes	2	1	10

Classe	Sensibilité	Spécificité	Précision	Prévalence
Chasseurs (menace à l'écosystème)	76.92%	100%	100%	86,67%
Non chasseurs (protecteurs de la faune... par inactivité)	100%	66.67%	66.67%	13,33%
Inconnu (ni chasseurs, ni pacifistes... des félins sous couverture)	NULL	NULL	NULL	0%

Ces résultats nous montrent que même si les chats de test proviennent d'Australie, nous arrivons à entraîner un modèle prédictif concluant pour un jeu de données provenant d'une nouvelle géolocalisation. Nous devons cependant considérer certaines limites. En effet, notre nouveau jeu de données à une taille restreinte.

DISCUSSION

Analyse critique des résultats

L'**analyse exploratoire** a permis de mettre en évidence une **variabilité intra-classe importante** : tous les chats stérilisés ou vivant exclusivement en intérieur ne renoncent pas nécessairement au comportement de prédation. Cette observation souligne la **complexité des comportements animaliers**, qui résultent d'une interaction subtile entre facteurs biologiques, environnementaux et individuels.

Du point de vue **méthodologique**, l'application du **clustering k-means** n'a pas permis d'**identifier les trois profils** principaux, les coefficients de silhouette traduisent un recouvrement important entre les groupes. Cela suggère que la **classification stricte** en clusters homogènes est **peu adaptée pour des comportements aussi nuancés** que ceux de la chasse. La **LDA** a quant à elle permis de **mieux séparer** les classes « chasse » et « non chasse », sans toutefois atteindre une séparation parfaite. Enfin, l'utilisation de l'**AutoML via auto-sklearn** a permis d'**améliorer la précision** globale des modèles, en testant de manière systématique différents algorithmes, ce qui confirme l'intérêt d'associer apprentissage machine et méthodes statistiques traditionnelles pour traiter ce type de problématique complexe. Néanmoins, la méthode de k-NN semble particulièrement adaptée à notre jeu de données. Une utilisation préférentielle de cette dernière dans ce contexte est à privilégier pour gagner en précision mais aussi en temps de calcul.

Limites et observations

Plusieurs limites doivent être soulignées concernant les résultats obtenus. Tout d'abord, la **présence d'une proportion non négligeable d'individus classés comme « Unknown »** pour la variable Hunt a compliqué l'apprentissage supervisé, en introduisant une incertitude supplémentaire dans la modélisation des comportements.

Ensuite, un **biais d'échantillonnage** est à noter : les données utilisées proviennent majoritairement de l'Australie, ce qui limite la généralisation des résultats à d'autres contextes écologiques, notamment aux populations de chats domestiques vivant dans des environnements ruraux européens tels que la France.

Enfin, **certaines variables environnementales potentiellement déterminantes**, telles que la densité de la faune locale ou le type d'habitat précis, **n'étaient pas disponibles**, restreignant ainsi la capacité du modèle à intégrer pleinement l'ensemble des facteurs influençant le comportement de chasse.

On peut noter également que l'approche avec **Knime** ne fut pas pertinente de part notamment la quantité de données analysées (*limitation à 99 999 lignes*). De même avec la **pipeline R**, les calculs étaient coûteux en termes de temps, de capacité mémoire et énergétique. L'utilisation d'un **cluster de calcul** ou du **GPU** de la machine est recommandé pour diminuer le temps de calcul (*CPU Ryzen 9 8945H 5.6GHz 8cores+16virtuals mémoire 32Gb DDR5 : 40 minutes d'exécution // CPU Intel Core i5-8350U 3.5GHz 4cores+8virtuals mémoire 8Gb DDR3 : 2 heures 30 minutes d'exécution*).

Conclusion sur la qualité des méthodes

Les méthodes mises en œuvre ont globalement permis d'atteindre plusieurs objectifs majeurs. D'une part, la **complexité** initiale du jeu de données a été **réduite** grâce à l'application de **techniques de normalisation** et de **réduction dimensionnelle**, facilitant ainsi l'analyse. D'autre part, des **structures significatives** ont pu être **extraites** au sein de la population étudiée, mettant en évidence des regroupements comportementaux pertinents. Enfin, il a été possible de **prédire** de manière raisonnablement fiable le **comportement de chasse** des individus à partir de leurs caractéristiques biologiques et environnementales.

Cependant, des méthodes appliquées, **aucune n'a permis d'atteindre une classification parfaite**, ce qui reste conforme aux attentes pour l'étude d'un comportement aussi multifactoriel et variable que la prédation chez le chat domestique. La **combinaison d'approches statistiques classiques**, telles que l'Analyse en Composantes Principales et l'Analyse Discriminante Linéaire, avec des **méthodes d'apprentissage automatique automatisé**, s'est révélée particulièrement **pertinente** pour appréhender cette problématique complexe de manière complémentaire et robuste.

BILAN ET PERSPECTIVES

Bilan général

Le projet **Félinomicon** a permis de construire une chaîne d'analyse complète, de la **préparation des données à l'interprétation écologique des résultats**. Nous avons réussi à :

- Nettoyer et structurer un jeu de données complexe et bruité.
- Explorer, visualiser et comprendre les principales tendances comportementales.
- Modéliser et prédire partiellement le comportement de chasse à partir de caractéristiques individuelles.
- Comparer les apports respectifs de méthodes statistiques classiques et d'approches automatiques par AutoML.

Une estimation de l'empreinte carbone a été effectuée et révèle une **consommation faible de notre projet** (~0.05 g CO₂ par an et ~6 g CO₂ pour 1 heure d'analyse). Une évaluation plus avancée n'est à priori pas nécessaire, en effet la consommation est largement raisonnable à ce niveau de notre projet. Une réévaluation pourra être envisagée dans le cas d'une amélioration des caractéristiques et du déploiement de **Félinomicon**.

Ce qui a bien fonctionné

- **Automatisation des prétraitements** : L'utilisation de scripts R pour extraire, normaliser et nettoyer les données.
- **Visualisations multiples** : L'application combinée a permis d'obtenir des représentations robustes de la structure des données.
- **Utilisation complémentaire d'AutoML** : Permettant de tester sans biais une large palette de modèles sans avoir à les paramétrer manuellement.
- **Approche progressive** : Enchaîner [exploration → clustering → modélisation supervisée] a facilité la compréhension des résultats à chaque étape.
- **Validation externe** : L'utilisation d'un jeu de données nouveau a permis d'éprouver le modèle et de confirmer la bonne conformité de celui-ci.

Ce qui aurait pu être amélioré

- **Traitement des individus "Unknown"** : Leur présence a complexifié l'entraînement des modèles. Une stratégie plus stricte de filtrage aurait pu être appliquée dès le début.
- **Qualité des variables disponibles** : L'absence de données environnementales contextuelles (type d'habitat, richesse en faune locale) a probablement limité la capacité explicative des modèles.

Recul sur la démarche

La conduite du projet a respecté une progression logique et scientifique :

analyse exploratoire → structuration de la base → modélisation → évaluation critique

Le choix de méthodes simples dans un premier temps, puis l'introduction d'approches plus avancées (AutoML) a permis une montée en complexité maîtrisée. Cela a facilité la compréhension fine des phénomènes, sans se contenter d'une approche purement algorithmique "boîte noire".

En termes de gestion de projet, la rigueur dans la séparation des étapes et la documentation progressive ont fortement contribué à maintenir la cohérence du travail, malgré la complexité croissante.

Pistes d'amélioration et perspectives

Si c'était à refaire :

- Nous intégrerions dès le départ un **filtrage plus strict** des individus ayant des données incomplètes ou douteuses.
- Nous prévoirions une **intégration de sources externes** pour enrichir les variables environnementales (cartes d'occupation du sol, bases ornithologiques locales...).
- Nous testerions également des méthodes **semi-supervisées** (e.g., clustering supervisé) pour mieux exploiter les classes partiellement connues.

À plus long terme, ce projet ouvre plusieurs perspectives :

- **Approche longitudinale** : Étudier l'évolution du comportement de chasse à travers le temps pour chaque individu.
- **Développement d'outils d'aide à la gestion écologique** : Utiliser les modèles prédictifs pour cibler les populations de chats nécessitant des actions de conservation spécifiques.
- **Adaptabilité du projet au public** : Créer une interface *user-friendly* afin que les non-initiés puissent renseigner les caractéristiques de leur chat pour connaître la probabilité de prédation de leur animal. Cela permettrait de recueillir davantage de données diverses pour améliorer le modèle et augmenter la précision de la prédiction.
- **Prédiction à partir d'informations visuelles** : Ajouter un nouveau modèle de prédiction basé sur la reconnaissance d'images.
- **Conseils spécifiques pour protéger l'écosystème** : Définir des comportements à suivre en fonction de la prédation estimée du chat et adapté à son mode de vie (extérieur / intérieur, seul / colocation animale ...).
- **Prédiction des valeurs manquantes** : Améliorer notre modèle afin de prédire les NA pour Hunt, N.pray, Hrs.indors.

CONCLUSION GÉNÉRALE

Le projet **Félinomicon** a permis d'explorer de manière systématique l'impact écologique des chats domestiques à partir de données comportementales et de mobilité. Grâce à une approche mêlant fouille de données, modélisation statistique et apprentissage automatique, nous avons conçu un modèle prédictif du comportement de prédation chez le chat domestique. Malgré la complexité intrinsèque du phénomène étudié, les méthodes mises en œuvre ont produit des résultats robustes et ont ouvert des perspectives d'amélioration pour des analyses futures à plus grande échelle.

GESTION DU PROJET

Organisation du groupe

Le travail a été mené de manière **presque collaborative** au sein d'un groupe composé de AMOUROUX Jan, RODRIGUES Camille-Astrid et BRAHIMI Célia. Les rôles ont été fluides : chaque membre pouvait intervenir sur l'analyse d'un autre en cas de besoin, favorisant une **compréhension transversale** du projet, notamment grâce à l'utilisation de **GitHub** et de **Discord**. Dès le début du projet, une **répartition des tâches** a été établie, accompagnée de **réunions hebdomadaires** autant que possible pour assurer le suivi de l'avancement. Les décisions importantes (choix méthodologiques, outils utilisés, structure du rapport) ont été prises à l'issue de discussions, souvent guidées par des résultats intermédiaires.

Méthodologie de travail

- **Aide extérieure** :
Le projet a été réalisé en autonomie, sans recours à une aide extérieure formelle.
- **Utilisation d'Intelligence Artificielle** :
Nous avons eu recours à ChatGPT uniquement pour assister à la relecture et pour structurer la rédaction du rapport.



Il est important de noter qu'aucun morceau de code final utilisé pour les analyses n'a été généré directement par une IA : toutes les parties critiques du pipeline de traitement de données et de modélisation ont été développées manuellement et validées entre membres du groupe.

Diagramme de Gantt

Tâche	Début	Fin	Responsable(s)
Obtention des matrices initiales	11/03/2025	13/03/2025	AMOUROUX, RODRIGUÈS
Formatage des données : matrice qualitative	17/03/2025	18/03/2025	AMOUROUX, RODRIGUÈS, BRAHIMI
Formatage des données : matrice quantitative	30/03/2025	01/04/2025	AMOUROUX, RODRIGUÈS
Approche naïve avec KNIME	12/04/2025	14/04/2025	AMOUROUX
Finalisation des prétraitements et prévisualisation sur R	16/04/2025	17/04/2025	RODRIGUÈS
Clusteror	23/04/2025	24/04/2025	AMOUROUX
ModeleR	23/04/2025	26/04/2025	RODRIGUÈS
Rédaction du rapport et finalisation GitHub	24/04/2025	27/04/2025	AMOUROUX, RODRIGUÈS

Épilogue : une plongée dans l'invisible

Au terme de cette exploration systématique, force est de constater que la compréhension du comportement écologique des chats domestiques demeure, en partie, **voilée d'une part d'inconnu**.

Malgré l'effort méthodique pour extraire des structures cachées et modéliser les dynamiques comportementales, des zones d'ombre subsistent, échappant aux cadres stricts de nos analyses statistiques.

À l'image des écrits ésotériques du **Nécronomicon** — ce livre fictif évoqué par Lovecraft, répertoriant des savoirs aussi anciens que terrifiants — **le Félinomicon** que nous avons bâti révèle une facette de la vérité... tout en suggérant l'existence d'autres forces plus profondes, encore hors d'atteinte de notre entendement scientifique.

L'instinct prédateur du chat domestique, en dépit de son environnement domestiqué, semble animé par des pulsions archaïques, **résurgences silencieuses de forces naturelles primordiales**.

À mesure que nous faisons reculer l'obscurité par la rigueur méthodologique, une part du réel demeure éternellement voilée, **murmurant à travers les modèles imparfaits comme le bruissement d'anciens vents dans les bibliothèques interdites**. Le **Félinomicon** reste donc une porte entrouverte, un appel à poursuivre l'exploration des comportements animaliers, entre **lumière de la raison** et **vertige du mystère biologique**.

Au terme de cette exploration, il nous reste à reconnaître que derrière chaque modèle, chaque cluster, se cache un univers dont l'étrangeté excède nos plus hardies tentatives de compréhension.

"Not only is the universe stranger than we imagine, it is stranger than we can imagine."
— Sir Arthur Eddington

Date de validation du document : 28/04/2025

AMOUROUX Jan

BRAHIMI Célia

RODRIGUÈS Camille-Astrid

